

Compte Rendu : Tâche 4

Analyse de Robustesse et Algorithmes d'Ensemble

Nour Nejia Chatti


1 Introduction

Cette section se concentre sur l'interprétabilité et la fiabilité du modèle **Random Forest**. Nous cherchons à prouver que nos prédictions sont non seulement précises, mais surtout **stables**, c'est-à-dire peu sensibles aux variations aléatoires lors de l'apprentissage.

2 Analyse de l'Importance des Features

Le Random Forest offre une vision claire des variables discriminantes. La capture suivante montre que le modèle identifie des patterns métiers logiques (durée de l'appel et antécédents de succès).

FIGURE 1 – Hiérarchie des variables décisionnelles (Top 10)




3 Analyse Approfondie de la Stabilité (Robustesse)

Concept de Stabilité

La stabilité garantit que le modèle a bien appris les structures réelles du dataset et non un "bruit" spécifique à un découpage des données. Dans un Random Forest, le hasard intervient à deux niveaux : le choix des lignes (*Bagging*) et le choix des colonnes (*Feature Selection*).

Protocole de test : Pour démontrer cette robustesse, nous avons fixé les paramètres optimaux (`max_depth=10`) et exécuté le modèle 5 fois en changeant systématiquement la graine aléatoire (`random_state`).

FIGURE 2 – Étude de Stabilité : Comparaison de 5 entraînements indépendants



Analyse des résultats : Comme illustré sur la capture ci-dessus, les scores oscillent entre 89.85% et 90.03%. Cette variance extrêmement faible ($< 0.2\%$) confirme que la forêt aléatoire parvient à moyenniser efficacement l'erreur. Le modèle est **reproductible** et fiable pour une mise en production.

4 Analyse Qualitative des Erreurs

L'inspection des résidus via notre dashboard permet de comprendre pourquoi le modèle échoue sur certains profils spécifiques malgré une accuracy globale élevée.

FIGURE 3 – Capture du Dashboard : Analyse des exemples mal classés

3. Analyse Qualitative (Erreurs)				
Voici quelques profils réels où le modèle s'est trompé (données originales du dataset) :				
Age	Durée	Solde	Réel	Pred
31	257s	6281€	OUI	NON
49	687s	99€	OUI	NON
47	236s	2408€	NON	OUI
55	247s	1693€	NON	OUI
Pattern : Les lignes jaunes sont des Faux Négatifs (clients qui ont souscrit mais que l'IA n'a pas détectés). Les lignes rouges sont des Faux Positifs (l'IA a prédit une souscription mais c'était incorrect). Notez les profils des seniors (60+ ans) : le dataset Bank Marketing contient peu de seniors, ce qui explique les erreurs de prédiction sur ces segments.				

4.1 Identification des Patterns d'Échec

- **Faux Négatifs (Lignes Jaunes) :** Le modèle a tendance à être trop conservateur. Par exemple, un client de 31 ans avec un solde élevé (6281) a été prédit "NON" car la durée de l'appel (257s) a été jugée insuffisante par l'algorithme pour valider une conversion.
- **Faux Positifs (Lignes Rouges) :** Le modèle confond parfois l'engagement poli avec une intention d'achat. Un appel long (> 400s) sur un profil senior peut induire l'IA en erreur, prédisant un "OUI" là où le client finit par décliner.

4.2 Synthèse des Cas d'Erreur

Type d'erreur	Age	Solde	Durée	Réel	Diagnostic Technique
Faux Négatif	31	6281€	257s	1	Poids excessif de la variable Duration
Faux Négatif	49	99€	687s	1	Solde faible masquant l'intérêt
Faux Positif	47	2408€	236s	0	Zone d'incertitude (200-300s)
Faux Positif	55	1693€	247s	0	Biais lié au segment d'âge senior

TABLE 1 – Patterns d'erreurs extraits du dataset original.

4.3 Analyse du Paradoxe Solde/Durée

L'analyse comparative de deux profils types révèle une dépendance excessive à la dynamique de l'appel :

- **Le Faux Négatif (Solde Élevé) :** Pour un client avec un solde de 6281 et 257s de durée, le modèle prédit "NON". L'IA applique ici une règle statistique rigide : en dessous d'un certain seuil de temps, elle considère que la vente ne peut être finalisée, ignorant la solidité financière du profil.

- **Le Faux Positif (Solde Faible) :** À l'inverse, des profils avec des soldes plus faibles mais des durées similaires sont prédits "OUI". Cela indique que le modèle entre dans une **"Zone Grise"** d'incertitude entre 200s et 300s, où de petites variations sur des variables secondaires (âge ou mois) font basculer la décision de manière erronée.


4.4 Synthèse des Cas d'Erreur

Type d'erreur	Age	Solde	Durée	Réel	Diagnostic Technique
Faux Négatif	31	6281€	257s	OUI	Domination du seuil temporel
Faux Négatif	49	99€	687s	OUI	Biais de durée excessive requise
Faux Positif	47	2408€	236s	NON	Instabilité dans la Zone Grise
Faux Positif	55	1693€	247s	NON	Biais lié au segment d'âge senior


5 Preuves Expérimentales : Biais et Variance

L'ajustement de la profondeur est le levier principal pour équilibrer le modèle.

FIGURE 4 – Visualisation du compromis Biais-Variance




Prof. 2 : Underfitting



Prof. 10 : Optimal

FIGURE 5 – Visualisation de l'Overfitting (Variance élevée)



Prof. 50 : Mémorisation du bruit (100% Train Acc.).

6 Synthèse et Comparaison Finales

Le Random Forest réduit la variance par le vote majoritaire. En agrégeant 100 arbres, il "lisse" les décisions extrêmes, ce qui le rend beaucoup plus stable que les modèles simples.

Configuration	Train Acc.	Test Acc.	Diagnostic
max_depth=2	88.3%	88.3%	Sous-apprentissage
max_depth=10	89.9%	91.4%	Stable / Optimal
max_depth=50	100.0%	90.0%	Sur-apprentissage

7 Conclusion

La Tâche 4 valide la supériorité du Random Forest. Sa robustesse, prouvée par MLflow, et l'analyse de ses erreurs montrent que le modèle a atteint une limite structurelle liée aux variables disponibles. Pour progresser, une ingénierie de variables plus fine sur la "Zone Grise" (durées moyennes) serait nécessaire.