

Projet MLA — Tâche 4

Interprétation et analyse des algorithmes d'ensemble

Random Forest

1. Contexte

Dans les phases précédentes du projet, vous avez réalisé :

- la collecte des données,
- le nettoyage et la préparation des données,
- la conception des interfaces Homme-Machine.
- L'expérimentation des algorithmes ML (KNN, SVM, Régression linéaire, Régression Logistique et arbre de décision)
- Le lien entre le back-end et le Front-end

La Tâche 4 consiste à appliquer l'algorithme Random Forest sur les données de votre projet, analyser et interpréter les résultats obtenus en répondant aux questions de TP réalisé durant la dernière séance du cours (les questions sont présentées dans ce qui suit)

Notez : Toutes les expérimentations devront être suivies et documentées à l'aide de MLflow.

Projet dont la tâche est une classification :

1. Explorer l'**importance des features** en utilisant `feature_importances_` de l'objet Random Forest entraîné
 - Visualiser le résultat à l'aide d'un graphique
 - Quelles sont les 3 variables les plus importantes pour la classification ? Cela correspond-il à votre compréhension des données ?
2. **Stabilité des prédictions** : En utilisant `random_state` différent, observez-vous une grande variabilité dans les résultats ? Que cela dit-il sur la robustesse du modèle ?
3. **Analyse des erreurs** : Prenez 2-3 exemples mal classés et analysez pourquoi le modèle a échoué. Y a-t-il des patterns dans ces erreurs ?
4. **Biais et Variance** : Tester différents hyperparamètres du `RandomForestRegressor` (par exemple, `n_estimators`, `max_depth`) et observer leur impact sur les performances. Etudier le biais et la variance dans chaque cas.
 - Vous pouvez remplir le tableau suivant:

Tableau d'analyse:

`n_estimators` | `max_depth` | Train Accuracy | Test Accuracy | Biais | Variance |

et répondre aux questions :

- Quel paramétrage montre overfitting ?
 - Quel paramétrage montre underfitting ?
 - Quel paramétrage semble équilibré ?
5. Comparez les résultats obtenus avec ceux de l'algorithme Arbre de décision.

Projet dont la tâche est une régression:

1. **Analyse des résidus:** Les résidus sont-ils distribués normalement ? Y a-t-il des patterns (hétéroscédasticité) ?
2. **Métriques de performance :** Comparez MAE, MSE et R^2 . Quelle métrique est la plus informative pour votre problème ?
3. **Impact des variables :** Comment une augmentation d'une unité de la variable X affecte-t-elle la variable cible, toutes choses égales par ailleurs ?
4. **Comparaison de features :** Quelle variable a le plus grand pouvoir prédictif ? Est-ce cohérent avec la théorie ?
5. **Biais et Variance :** Tester différents hyperparamètres du RandomForestRegressor (par exemple, n_estimators, max_depth) et observer leur impact sur les performances. Etudier le biais et la variance dans chaque cas.

- Vous pouvez remplir le tableau suivant:

Tableau d'analyse:

n_estimators | max_depth | Train RMSE | Test RMSE | Biais | Variance |

et répondre aux questions (limite du modèle): Dans quelles plages de valeurs le modèle performe-t-il moins bien ? Pourquoi ?

6. Comparez les résultats obtenus avec ceux de l'algorithme Arbre de décision.

Compte Rendu :

Un document qui contient des réponses claires et justifiées pour chaque question.